CSED226 데이터분석 입문 practice1 report

컴퓨터공학과 20240940 장해영

1. Introduction

해당과제는 wide-format으로 구현된 런던 자전거 대여 시나리오에 대한 csv파일을 tidy-format으로 변환하여 다시 csv와 parquet 두 가지의 형식으로 저장하는 것이다. 이 때 파이썬의 라이브러리인 numpy와 pandas를 쓰지 않고 문제를 해결하여야 한다. 이를 구현하는 방법은 여러가지가 있으므로 이 보고서에서는 내가 짠 코드와 reference code의 차이에 대해 다뤄보고자 한다.

2. Difference with Reference code

A. 구현상의 차이점

wide-format의 csv파일을 tidy-format으로 변환하기 위해 내가 사용한 방법은 wide_to_tidy()함수를 만들어 이 안에서 모든 단계를 수행하는 것이었다. Wide-format의 csv파일을 읽어낸 후 바로 tidy-format으로 변환하도록 코드를 짜면 된다고 생각하여 이를 하나의 함수에 담아낸 것이었다. 중간에 결측치를 다루기 위해 결측지를 구분하는 함수만 추가하였을 뿐, 최종목적을 위한 기능을 하는 함수는 wide_to_tidy() 하나로 구성하였다.

반면, reference code에서는 tidy-format을 구성하는 TidyRow라는 클래스를 만들어 사용하였다는 것이 인상적이었다. 또한 parse_count, hour_to_dt, wide_csv_rows, rows_to_tidy 등 각각의 기능을 하는 함수를 모두 따로 구현하여 함수의 역할을 명확히 구분하였다. 또한 csv와 parquet에 정보를 작성하는 것 또한 각각의 함수를 만들어 구분지었다. 이 함수들을 최종적으로 main에서 호출하여 기능을 구현하였다. 이렇게 각 기능을 여러 함수로 나누면 가독성이 훨씬 뛰어나게 코드를 짤 수 있다는 확실히 느꼈다.

이것이 내가 짠 코드와 reference code의 가장 큰 차이점이다. 나의 코드는 전체적으로 함수 하나만을 이용하여 기능을 구현하였다면, reference code는 함수 여러 개를 이용하여 기능을 나눈 것이다.

B. 데이터 핸들링에서의 차이점

데이터를 핸들링하는 과정에서도 나의 코드와 reference code간의 차이를 느낄 수 있었고, 크게 두 가지를 느낄 수 있었다.

i. 결측치

결측치가 있는 자료를 처리하는 방법에서 차이가 있었다.

나는 csv파일의 경우, 결측치에 해당하는 자료의 count값에 "None"이라는 텍스트를 넣고, parquet파일의 경우 count값에 문자열을 입력할 수 없었기 때문에 아무것도 입력하지 않고 아예 그 자료를 결과파일에 넣지 않는 방향으로 코딩하였다.

반면, reference code에서는 csv파일과 parquet파일에서 모두 count값이 결측지인 경우 빈 문자열인 ""를 출력하였다.

"None"을 출력하거나 아예 값을 없애버리는 것 보다는, 빈문자열을 출력하는 것이 결측치라는 것을 나타내는 목적에 더 부합하는 것 같다.

ii. 타임스탬프

내가 짠 코트에서 타임스탬프를 나타내는 문자열을 만드는 과정에서, 위치정보를 객체에 추가하지 않고, 문자열에만 더하는 방식으로 구현하였다. 주어진 데이터내에서만 다루는 거라, 굳이 객체에 추가하지 않아도 된다고 생각하였다.

반면, reference code에서는 객체 자체에 위치정보를 저장하였다. 만약 주어진 데이터 외에, 다른 지역정보가 담긴 데이터를 이용하여 분석을 진행해야하는 상황이 발생한다면, 객체에 지역정보를 저장해야 어느 지역이 주어지든 제대로 된 분석을 진행할 수 있을 것이다.

3. Result and Lessons

이 보고서에서는 내가 짠 코드와 reference code를 비교해보았다. 스스로 코드를 짤 때에는 쉽고 간단하게 코딩하는 것 만을 생각했지만, reference code는 확실히 가독성을 중시한 코드라고 생각이 들었다. 또한 다음 과제에서는 주어진 데이터 이외에 다른 데이터를 이용하여 분석해야하는 상황까지 고려해야겠다는 교훈을 얻었다.

특히, 하나의 함수에 모든 기능을 넣지 않고, 하나의 기능은 하나의 함수에서 수행하도록 코딩한 뒤 main함수에서 이 함수들을 조합하는 방식으로 코딩할 수 있도록 노력해야겠다.

마지막으로, tidy-format의 중요성도 깨달았다. 주어진 데이터 형식은 wide-format은 많은 요소에 대한 정보가 한 행에 포함되어 있어 어떤 것을 의미하는 지 쉽게 알 수 없었다. Tidy-format으로 변환한 뒤 csv파일을 열어 데이터를 확인하니 한 행에 한 요소만 저장되어 있어 정보를 쉽게 알 수 있었다.